

# Simulação das propriedades da exponencial

## Importar bibliotecas

```
In [12]: import time
import numpy as np
import scipy.stats as st
```

## Probabilidade de uma variável aleatória exponencial ser menor do que outra

Sejam  $X_1$  e  $X_2$  variáveis aleatórias independentes com média  $\mu_1 = 1/L_1$  e  $\mu_2 = 1/L_2$

- $P[X_1 \leq X_2] = \frac{L_1}{L_1 + L_2}$

Podemos simular essa probabilidade com o seguinte algoritmo vetorial, implementado na função **pExpMenor**.

- Sortear array  $exp_1$  com  $nSim$  valores exponenciais com média  $\mu_1$ .
- Sortear array  $exp_2$  com  $nSim$  valores exponenciais com média  $\mu_2$ .
- Calcular vetor  $menor$  com valores *True* se  $exp_1 < exp_2$ .
- Retornar a quantidade de elementos no vetor  $menor$  contendo valor *True*, dividida por  $nSim$ .

```
In [13]: def pExpMenor(MU1, MU2, nSim):
exp1 = st.expon.rvs(scale=MU1, size=nSim)
exp2 = st.expon.rvs(scale=MU2, size=nSim)
menor = exp1 < exp2
return np.count_nonzero(menor) / nSim
```

O código a seguir compara o valor de probabilidade simulado pela função **pExpMenor** com o valor teórico.

```
In [14]: mu1 = 2
mu2 = 4
nSim = 10000

probT = (1/mu1)/(1/mu1+1/mu2)
t1 = time.perf_counter()
probS = pExpMenor(mu1, mu2, nSim)
t2 = time.perf_counter()
print('Probabilidade simulada: {:.4f}'.format(probS))
print('Probabilidade teórica: {:.4f}'.format(probT))
print('Tempo de simulação: {:.4f}'.format(t2-t1))
```

Probabilidade simulada: 0.6667

Probabilidade teórica: 0.6667

Tempo de simulação: 0.0028

## Distribuição da soma de $N$ variáveis aleatórias exponenciais

Sejam  $X_1, X_2, \dots, X_N$  variáveis aleatórias independentes com média  $\mu_{X_1} = 1/L$ .  
 $X = X_1 + X_2 + \dots + X_N$  tem distribuição Erlang com parâmetros  $N$  e  $L$ .

- $f_X(x) = \frac{L^N x^{N-1} e^{-Lx}}{\tau(N)}$
- $F_X(x) = 1 - \sum_{j=0}^{N-1} e^{-Lx} \frac{(Lx)^j}{j!}$

Com a biblioteca Scipy temos:

- $P[X \leq x] = \text{st.gamma.cdf}(x, a=N, \text{scale}=MU)$

## Algoritmo iterativo

Podemos calcular simular a CDF da soma de  $N$  variáveis aleatórias exponenciais com média  $MU$  com o seguinte algoritmo iterativo:

- Iniciar a variável *deuCerto* com zero.
- Sortear o array *EXP* com  $N$  variáveis aleatórias com média  $MU$ .
- Calcular o array *soma* contendo o somatório de *EXP*, ou seja, a soma de  $N$  variáveis aleatórias exponenciais com média  $MU$ .
- Incrementar *deuCerto*, e a soma for menor do que o valor  $x$  para o qual queremos calcular a CDF (passado com argumento).
- Retornar *deuCerto* dividido por *nSim*.

```
In [15]: def somaExpCDFI(x, N, MU, nSim):  
    deuCerto = 0  
    for i in range(nSim):  
        EXP = st.expon.rvs(scale=MU, size=N)  
        soma = sum(EXP)  
        if soma <= x:  
            deuCerto = deuCerto + 1  
    return deuCerto/nSim
```

O código a seguir compara o valor de probabilidade simulado pela função **somaExpCDFI** com o valor da CDF da variável gamma calculado pela biblioteca Scipy.

```
In [16]: x = 25  
N = 10  
MU = 3  
nSim = 100000  
  
probT = st.gamma.cdf(x, a=N, scale=MU)  
t1 = time.perf_counter()  
probS = somaExpCDFI(x, N, MU, nSim)  
t2 = time.perf_counter()  
print('Probabilidade simulada: {:.4f}'.format(probS))  
print('Probabilidade teórica: {:.4f}'.format(probT))  
print('Tempo de simulação: {:.4f}'.format(t2-t1))
```

```
Probabilidade simulada: 0.3231  
Probabilidade teórica: 0.3255  
Tempo de simulação: 2.7193
```

## Algoritmo vetorial

Podemos calcular simular a CDF da soma de  $N$  variáveis aleatórias exponencias com média  $MU$  com o seguinte algoritmo vetorial implementado com a biblioteca numpy:

Sortear a matriz  $EXP$  com  $nSim$  linhas e  $N$  colunas.

- Observação: Cada linha corresponde a uma simulação e contém os valores das  $N$  exponencias sorteadas com média  $MU$ .
- Dica: usar `np.random.exponential(MU, [nSim, N])`

Calcular o array *soma* contendo o somatório de cada linha da matriz  $EXP$ , ou seja, cada elemento tem a soma de  $N$  variáveis aleatórias exponenciais com média  $MU$ .

- Dica: usar `np.sum()`, observando que tem que somar as linhas.

Calcular o array *menor* que contém *True* para cada linha da matriz cuja soma menor seja do que o valor  $x$  para o qual queremos calcular a CDF (passado com argumento).

- Dica: `(soma <= x)`

Retornar a quantidade de elementos no vetor *menor* contendo valor *True*, dividida por  $nSim$ .

- Dica: usar a função `np.count_nonzero` para contar a quantidade de elementos com valor *True*.

```
In [27]: def somaExpCDFV(x, N, MU, nSim):  
         array = []  
         for i in range(nSim):  
             EXP = np.random.exponential(MU, [nSim, N])  
             soma = sum(EXP)  
             array.append(soma<=x)  
         return np.count_nonzero(array)
```

O código a seguir compara o valor de probabilidade simulado pela função **somaExpCDFV** com o valor da CDF da variável gamma calculado pela biblioteca Scipy.

```
In [28]: x = 25
N = 10
MU = 3
nSim = 10

probT = st.gamma.cdf(x, a=N, scale=MU)
t1 = time.perf_counter()
probS = somaExpCDFV(x, N, MU, nSim)
t2 = time.perf_counter()
print('Probabilidade simulada: {:.4f}'.format(probS))
print('Probabilidade teórica: {:.4f}'.format(probT))
print('Tempo de simulação: {:.4f}'.format(t2-t1))
```

```
Probabilidade simulada: 30.0000
Probabilidade teórica: 0.3255
Tempo de simulação: 0.0027
```

## Entrega

Completar o algoritmo. Imprimir para PDF. Enviar no AVA>